# Fase B — Limpieza y normalización de datos

Proyecto 2 y 3
Dataset: Hurto de motocicletas y automotores en Colombia

Integrantes:
Diego Andrés Bolaños Isiquita (202379918)
Diego Alejandro Gómez Puentes (202411026)
David Stiven Mujanajinsoy Jajoy (202376834)

## 1. Objetivo y resultado

Esta fase prepara el reporte de Hurto por Modalidades de la Policía Nacional (656.635 registros, enero de 2010 a julio de 2026) para responder la pregunta de negocio: ¿es posible predecir cuántas motocicletas se hurtarán en un municipio el mes siguiente? El resultado es `datos_limpios.parquet`, con 182.350 filas (un municipio en un mes), 64 columnas y 0 nulos, entre enero de 2012 y julio de 2026. El proceso completo está en fase_b_limpieza.ipynb

## 2. Diagnóstico

- **Nulos:** solo `GENERO` (712, 0,11 %) y `GRUPO ETARIO` (205, 0,03 %).
- **Duplicados:** 218.780 filas idénticas. Sin número de denuncia no se pueden distinguir de hechos distintos, así que se conservan.
- **Texto:** sin espacios sobrantes, pero con cuatro inconsistencias (ver sección 4).
- **Fechas:** las 656.635 son válidas, con formato día/mes/año.
- **Columna sin información:** `CANTIDAD` vale siempre 1. La cantidad real se obtiene contando filas.
- **Subregistro de 2010:** 21.456 filas frente a 30.730 en 2011. Por eso la serie de modelado arranca en 2011.

## 3. Manejo de nulos: dos estrategias

| Columna | Estrategia | Por qué |
|---|---|---|
| `GENERO` (772 nulos tras convertir 'NO REPORTA') | Moda: MASCULINO | Es una variable nominal y la categoría dominante pesa más del 80 %, así que la distribución casi no cambia (80,81 % pasa a 80,84 %). La media y la mediana no aplican a texto. |
| `GRUPO ETARIO` (205 nulos) | Constante: NO REPORTADO | Conserva el hecho de que el dato faltaba. De todos modos la variable se descarta del modelo por ser 99,3 % adultos. |

No se usó KNN: con tan pocos nulos y variables categóricas poco informativas no aporta frente a la moda.

## 4. Inconsistencias de texto

- `GENERO` traía 60 registros `NO REPORTA`, un nulo disfrazado de categoría. Se convirtió a nulo y se imputó junto con los demás.
- `ARMAS MEDIOS` tenía cinco categorías que son todas arma blanca (cortantes, cortopunzantes, punzantes, armas blancas y arma blanca/cortopunzante). Se agruparon en una sola, y quedaron 8 categorías.
- `MUNICIPIO` llevaba el sufijo (CT) en 429.316 filas. Es una marca de cabecera municipal, así que se separó en la columna binaria `ES_CAPITAL_CT`.
- 58 nombres de municipio se repiten en distintos departamentos. La llave del municipio es **departamento + municipio**, lo que da 1.052 municipios.

## 5. Valores atípicos: se conservan

La tabla objetivo (motos por municipio-mes) tiene 194.854 filas, 1.042 municipios y 187 meses, con 71,1 % de ceros. Se aplicaron dos métodos:

- **IQR:** Q1 = 0, Q3 = 1 y límite superior = 2,5. Marca 22.137 casos (11,4 %). A nivel municipio-año marca 13,4 %.
- **Z-score (|z| > 3):** marca 1.062 casos (0,55 %), las grandes ciudades.

**Decisión: conservar todos.** Los motivos son estos:

- Son conteos reales, no errores de captura. El máximo (658 en Medellín en un mes) es plausible.
- El IQR está degenerado por los ceros: marca a cualquier municipio con 3 motos o más, no a valores raros. Tampoco el Z-score es confiable, porque asume una distribución casi normal y aquí la varianza es unas 150 veces la media.
- Los atípicos están repartidos en cientos de municipios y solo el 21,6 % corresponde a capitales (CT).
- Eliminarlos borraría justo a los municipios que más interesa predecir.
- Los meses extremos bajos (abril de 2020, noviembre y diciembre de 2012) corresponden a la cuarentena y a un hueco de registro, que son eventos reales o limitaciones documentadas.

## 6. Transformación logarítmica

La asimetría de las motos por municipio-mes es 18,56. Se compararon dos transformaciones:

| Transformación | Asimetría resultante | Observación |
|---|---|---|
| log(1 + x) | 2,80 | Conserva las diferencias de magnitud entre ciudades. |
| Yeo-Johnson | 1,01 | Con λ = −1,886 se satura (tope cercano a 0,53): Medellín con 400 motos y un municipio con 40 quedarían casi iguales. |

**Decisión: log(1 + x).** Se revierte con `expm1` para reportar el error en motos reales y coincide con lo definido en la Fase A. La asimetría no baja más porque unos 138.000 municipio-meses tienen cero motos, y ninguna transformación elimina esa masa de ceros. Se aplicó el mismo log a los rezagos de motos y de autos.

## 7. Variables de rezago

Para predecir el mes siguiente se construyeron cuatro variables que usan **solo meses anteriores**: motos del mes anterior, promedio de los 3 meses previos, motos del mismo mes del año anterior y autos del mes anterior. Se verificó con un ejemplo (Medellín) que el promedio de 3 meses no incluye el mes que se predice. El rezago de 12 meses exige un año de historia, por lo que las filas de 2011 quedan como historia y el modelado empieza en enero de 2012.

## 8. Codificación de variables categóricas

| Variable | Técnica | Por qué |
|---|---|---|
| `DEPARTAMENTO` | One-Hot, `drop_first=True` (32 columnas) | Es nominal: ningún departamento es mayor que otro. Se elimina una categoría para evitar la redundancia entre columnas. |
| `MES` | One-Hot, `drop_first=True` (11 columnas) | Es una categoría cíclica sin orden numérico real. Con números, diciembre pesaría 12 veces más que enero. |
| `GRUPO ETARIO` | Ordinal: menores (0) < adolescentes (1) < adultos (2) | Es la única variable con orden natural. Se muestra la técnica, pero no entra al modelo (99,3 % adultos). |
| `ES_CAPITAL_CT` | Ninguna | Ya es binaria (0/1). |

## 9. Escalado y partición temporal

- **Se escalan solo los 4 rezagos en log, con Z-score.** Ya están en la misma escala logarítmica y no tienen atípicos extremos. No se usó RobustScaler porque con tantos ceros su rango intercuartílico es casi degenerado, ni Min-Max por su sensibilidad a valores extremos.
- **No se escalan** las dummies ni el objetivo (`MOTOS_LOG`), para poder revertirlo directamente a motos reales.
- **Partición temporal:** entrenamiento de enero de 2012 a diciembre de 2024 (162.552 filas) y prueba de enero de 2025 a julio de 2026 (19.798 filas). El escalador se ajustó **solo con entrenamiento**, para que ninguna estadística de los meses de prueba influya en el modelo.
- Quedan 218.780 filas repetidas que se conservaron como hechos distintos por falta de un identificador de denuncia.