Fase A — Análisis exploratorio: los 3 hallazgos más importantes

Proyecto 2 y 3 · Introducción a la Ciencia de los Datos · Hurto de motocicletas y automotores en Colombia

Integrantes:

Diego Andrés Bolaños Isiquita (202379918)

Diego Alejandro Gómez Puentes (202411026)

David Stiven Mujanajinsoy Jajoy (202376834)

Datos: Reporte de Hurto por Modalidades, Policía Nacional — 656.635 registros, enero 2010 a julio 2026

Pregunta de negocio: ¿es posible predecir la cantidad de hurtos de motocicletas que se presentarán en un municipio durante el siguiente mes, usando el comportamiento histórico de los hurtos y las variables del dataset?

Cada fila del archivo es un vehículo hurtado; las únicas columnas numéricas (CANTIDAD, siempre 1, y CODIGO DANE, una etiqueta) no sirven para analizar por sí solas. Por eso construimos dos tablas: el perfil del hurto por municipio-año y la variable objetivo, motos hurtadas por municipio-mes. Esta última tiene 194.854 filas (1.042 municipios × 187 meses), con los meses sin hurtos completados con 0. Durante el diagnóstico encontramos que 58 nombres de municipio se repiten en distintos departamentos, así que la llave del municipio es departamento + municipio.

1. El hurto de vehículos está extremadamente concentrado

El problema es más concentrado que la regla 80/20: solo 52 de 1.052 municipios (4,9 %) reúnen el 80 % de los hurtos, y Bogotá, Medellín y Cali suman el 44 % del país.

En automotores la concentración es extrema: 18 municipios (2,0 %) hacen el 80 % y las tres grandes ciudades suman el 63 %. En motos el problema está algo más repartido: 61 municipios (5,9 %) y 38 % en las tres ciudades.

Qué significa para el negocio: contra el hurto de carros rinde una estrategia focalizada en pocas ciudades; contra el de motos hace falta cobertura en más territorios.

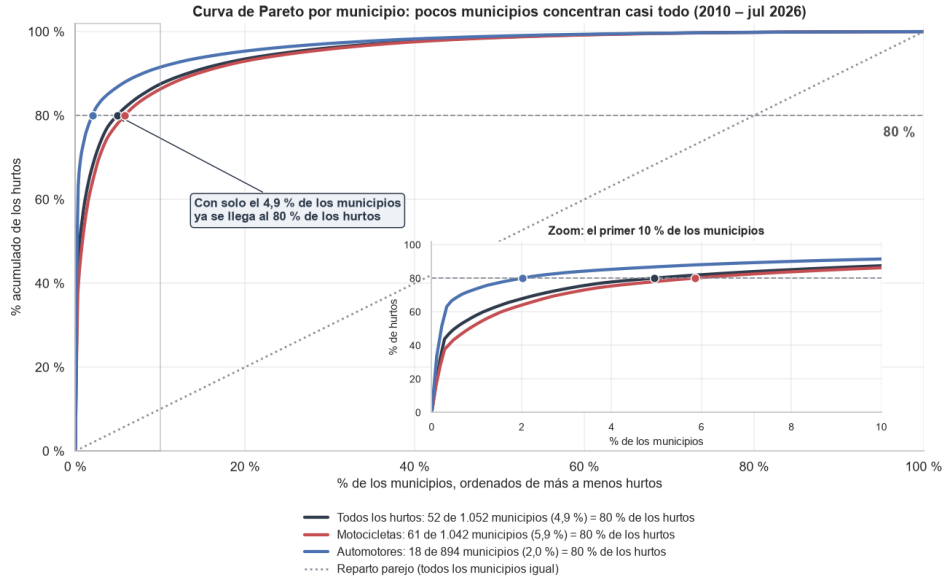


Figura 1. Curva de Pareto: % acumulado de hurtos según el % de municipios (2010 – jul 2026).

2. Las motos son el centro del problema y su tendencia ya cambió

Las motos son el 76 % de los hurtos. Pasaron de 20.448 en 2011 a 41.705 en 2023 (≈ ×2,0), mientras los automotores casi no cambiaron (×1,1).

Desde el pico de 2023 hay una baja sostenida: −17 % en motos y −19 % en automotores en 2025. La cuarentena de 2020 recortó el hurto de motos un 24 %.

Calidad de datos: el registro salta +59 % entre diciembre de 2010 y enero de 2011 (Medellín pasa de 151 a 546 casos al mes). 2010 está subregistrado y el crecimiento debe medirse desde 2011; si no, se infla a ×3,1.

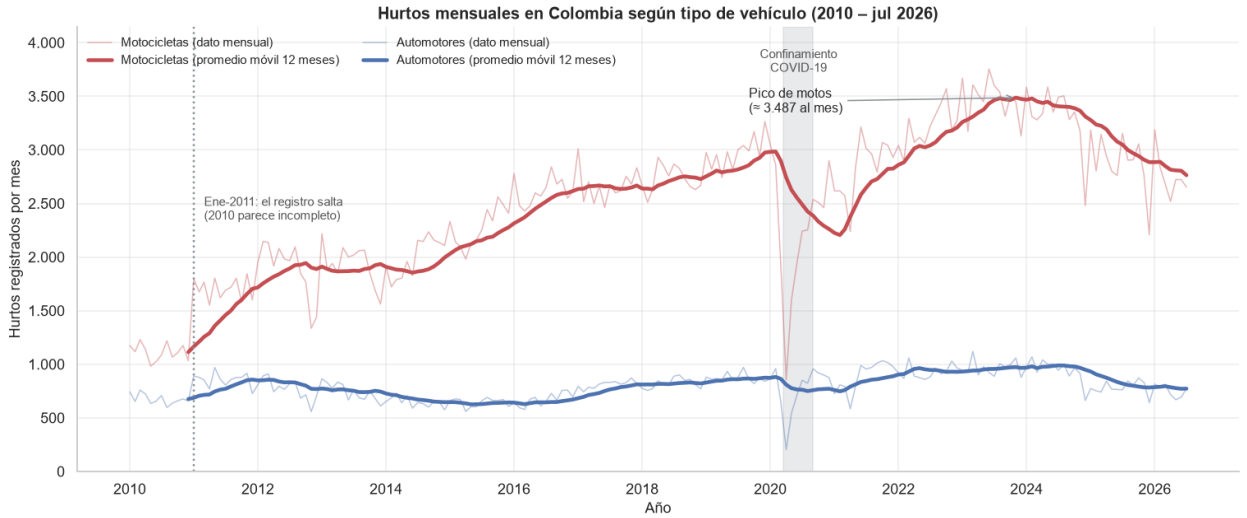


Figura 2. Hurtos mensuales por tipo de vehículo; líneas gruesas = promedio móvil de 12 meses.

3. El hurto de motos de un municipio se puede anticipar con su propia historia

Cada ciudad se mueve en su propia franja: Medellín ronda 415 motos al mes, Bogotá 307 y Cali 236, frente a unas 70 en Popayán o Barranquilla. Solo el promedio histórico de cada municipio explica el 92,5 % de la variación de la variable objetivo.

Mes a mes, la historia reciente anticipa el siguiente: la correlación de Spearman con el promedio de los 3 meses previos es 0,63 (0,61 con el mes anterior), y se mantiene en 0,48–0,53 en los municipios pequeños. El mismo mes del año anterior (0,58) no la supera, coherente con la poca estacionalidad: ningún mes se aleja más de ±4 % del promedio.

Respuesta preliminar a la pregunta: sí es viable. Una predicción ingenua ("igual al promedio de los 3 meses previos") ya se equivoca en promedio solo 0,84 motos por municipio-mes. Esa es la línea base que deben superar los modelos de la Fase C.

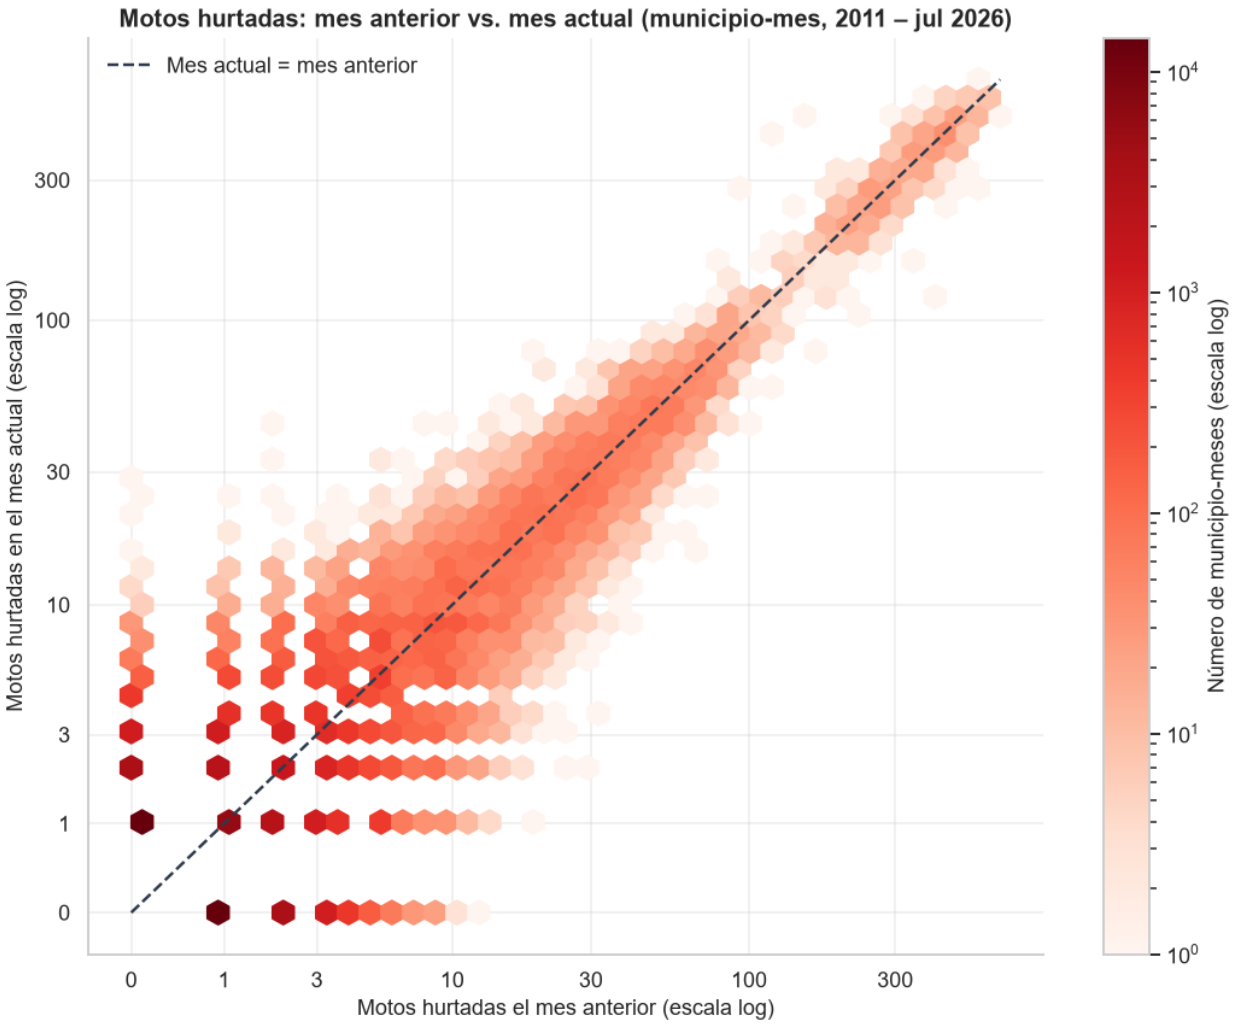


Figura 3. Motos hurtadas el mes anterior vs. el mes actual (municipio-mes, escala log). Los puntos siguen la diagonal.

Retos que impone la variable objetivo

- **Muchos ceros y cola larga:** en el 71 % de los municipio-meses no se hurtó ninguna moto, pero Medellín llega a 658 en un mes. La varianza es 150 veces la media y la asimetría de los conteos baja de 15,9 a 1,35 con log(1 + x).
- **Atípicos reales, no errores:** el 13,6 % de los municipio-años son atípicos por la regla de Tukey, pero corresponden a las grandes ciudades o a eventos (cuarentena de abril de 2020, hueco de registro en nov–dic 2012). Se conservan.
- **Variables con poca información:** GRUPO ETARIO es 99,3 % adultos y la modalidad cambió de criterio con los años (la llave maestra baja de 50 % a 19 %), así que no es comparable en el tiempo.

Implicaciones para las fases B y C

Fase	Decisión que se desprende del EDA
B · Limpieza	Transformar los conteos con log(1 + x); conservar los atípicos; imputar los pocos vacíos de GENERO (0,1 %) y descartar GRUPO ETARIO; One-Hot

	para modalidad y departamento; trabajar la serie desde 2011; conservar las filas repetidas (sin identificador de caso son hurtos distintos, no duplicados).
C · Modelos	Usar como variables la historia del municipio (mes anterior, promedio de 3 meses, mismo mes del año anterior, autos del mes anterior), el mes y el departamento. Separar entrenamiento y prueba en el tiempo para no usar información del futuro. Comparar cada modelo contra la línea base ingenua (error medio de 0,84) y revisar el error por separado en ciudades grandes y municipios pequeños.

Limitaciones

Son hurtos denunciados, no todos los ocurridos; 2026 llega solo hasta julio y 2010 está subregistrado. En la variable objetivo un 0 puede significar "no hubo hurtos" o "no se registró". Las correlaciones describen asociación, no causalidad.