

Hurto de vehículos en Colombia: bodega de datos y análisis exploratorio

1. Contexto y pregunta de negocio

Trabajamos con el reporte Hurto por Modalidades de la Policía Nacional de Colombia, que tiene 656.635 registros de hurtos de motocicletas y de automotores entre enero de 2010 y julio de 2026. Cada registro es un hurto reportado, con su fecha, municipio, arma o medio usado, y el género y grupo de edad de la persona afectada. Con estos datos diseñamos una bodega de datos en estrella (Fase A), la cargamos con un proceso ETL (Fase B), la consultamos con SQL (Fase C) y la visualizamos (Fase D).

Pregunta de negocio inicial: ¿es posible predecir la cantidad de hurtos de motocicletas que se presentarán en un municipio durante el siguiente mes, utilizando el comportamiento histórico de los hurtos y las variables disponibles en el dataset?

2. Preguntas de negocio abordadas

Para acercarnos a la pregunta de predicción hicimos seis preguntas descriptivas sobre la bodega. Esto es lo que respondió cada una:

Pregunta (Fase C)	Resultado principal
1. ¿Cómo ha evolucionado cada mes el total de hurtos?	Pasó de 1.916 casos en enero de 2010 a 3.427 en julio de 2026. El máximo fue 4.728 (marzo de 2023) y el mínimo 1.058 (abril de 2020).
2. ¿Qué departamentos concentran más hurtos?	Antioquia (21,94 %), Bogotá (17,27 %) y Valle (15,92 %) suman el 55,1 % del total nacional.
3. ¿Predominan los hurtos de motocicletas o de automotores?	Motocicletas: 497.736 casos (75,8 %). Automotores: 158.899 casos (24,2 %).
4. ¿Cuáles son los medios o armas más reportados?	Llave maestra (225.206; 34,3 %), sin empleo de armas (193.700; 29,5 %) y arma de fuego (190.560; 29,0 %).
5. ¿Qué combinaciones de género y grupo etario concentran más víctimas?	Hombres adultos (526.608; 80,2 %) y mujeres adultas (125.023; 19,0 %). Las demás combinaciones suman menos del 1 %.
6. ¿Qué municipios tienen más hurtos de motocicletas?	Medellín (78.821), Bogotá (60.259) y Cali (47.504). Estos tres suman el 37,5 % de los hurtos de motos del país.

3. Diagrama de la bodega

Usamos un modelo en estrella porque cada dimensión tiene pocos niveles (un municipio pertenece a un departamento y una fecha a un mes y a un año), así que podemos guardar cada dimensión en una sola tabla conectada directamente con la tabla de hechos. La granularidad de FACT_HURTOS es un hurto de vehículo reportado, en un municipio y una fecha determinados; su única medida es cantidad, que vale 1 en cada fila y se suma para obtener totales.





Tabla	Filas	Que contiene
FACT_HURTOS	656.635	Un hurto por fila, con las claves de las cinco dimensiones y la medida cantidad
DIM_FECHA	6.056	Fecha, año, trimestre, mes, día de la semana y si es fin de semana
DIM_MUNICIPIO	2.201	Código DANE, municipio, departamento e indicador de capital
DIM TIPO HURTO	2	Motocicletas o automotores
DIM_ARMA_MEDIO	12	Arma o medio usado y su categoría agrupada
DIM_VICTIMA	9	Combinaciones de género y grupo etario


En el ETL leímos el CSV con pandas, convertimos las fechas, estandarizamos los textos, llevamos los nulos de género y grupo etario a la categoría NO REPORTADO, creamos las claves sustitutas y cargamos todo a una base SQLite (hurto_dw.db). Comprobamos que la tabla de hechos tuviera exactamente las mismas 656.635 filas de la fuente, sin nulos en las claves y con la misma suma de cantidad.

4. Tres hallazgos clave


Los hurtos de motocicletas se triplicaron entre 2010 y 2023, y desde entonces bajan



Pocos municipios concentran los hurtos de motocicletas



La estacionalidad es débil: pesa más el nivel de cada año que el mes



5. Limitaciones

- Solo hurtos denunciados. Es probable que haya subregistro, y un cambio en la forma de reportar puede verse como un cambio del fenómeno. Por ejemplo, entre diciembre de 2010 y enero de 2011 los hurtos de motos pasaron de 1.033 a 1.798 en un solo mes, un salto que parece más de registro que real y que no pudimos explicar con los datos.
- Sin población ni parque de vehículos. El dataset no trae estos datos, así que comparamos municipios por volumen y no por tasa (por ejemplo, hurtos por cada 100.000 habitantes).
- Datos escasos por municipio. Si completamos con cero los meses sin hurtos, cerca del 72 % de las combinaciones municipio-mes tienen cero hurtos de motocicletas.
- Código DANE con centros poblados. DIM_MUNICIPIO tiene 2.201 filas aunque hay cerca de 1.050 municipios, porque algunos códigos corresponden a centros poblados. Por eso un municipio puede quedar repartido en varias filas (Medellín suma 78.821 por código y 79.574 por nombre) y la columna municipios_afectados de algunas consultas se sobreestima.
- Últimos meses y año 2020. Los datos más recientes pueden ajustarse todavía, y 2020 es atípico por la pandemia, lo que puede distorsionar un modelo de predicción.
- Sin número de denuncia. Hay 218.780 filas idénticas que son hechos distintos y no duplicados, pero no tenemos un identificador para comprobarlo.

6. Próximos pasos

Se podría entrenar primero una referencia simple (repetir el valor del mes anterior) y luego modelos de conteo y de árboles. Validar con división temporal (entrenar con los años anteriores y probar en los meses más recientes) y medir el error con MAE y RMSE. También otro paso sería agregar la población de cada municipio (DANE) para trabajar con tasas, y decidir si se modelan solo los municipios de mayor volumen o se agrupan los pequeños por departamento.