Fase C — Modelos predictivos: análisis y justificación del modelo elegido

Proyecto 2 y 3 · Hurto de motocicletas en Colombia

Integrantes: Diego Andrés Bolaños Isiquita (202379918)

Diego Alejandro Gómez Puentes (202411026),

David Stiven Mujanajinsoy Jajoy (202376834)

Datos: datos_limpios.parquet — 182.350 municipio-mes (1.042 municipios, ene 2012 a jul 2026)

Notebook: fase_c_modelos.ipynb

Pregunta de negocio: ¿es posible predecir la cantidad de hurtos de motocicletas que se presentarán en un municipio durante el siguiente mes, usando el comportamiento histórico de los hurtos? **Tipo de problema:** regresión (el objetivo, MOTOS, es un conteo).

1. Cómo se entrenaron y evaluaron los modelos

- **Variables predictoras (53):** historia del municipio conocida antes del mes a predecir (motos del mes anterior, promedio de 3 meses, mismo mes del año anterior, autos del mes anterior, en escala normal y log), más año, mes, departamento y si es capital. Se excluyeron las variables que filtran el resultado (MOTOS_LOG, autos del mismo mes) y las ya escaladas.
- **Split 80/20** con train_test_split (145.880 filas de entrenamiento y 36.470 de prueba); todas las métricas se calculan solo en prueba.
- **Sin data leakage:** el StandardScaler va dentro de un Pipeline y se ajusta solo con entrenamiento.
- **Prueba de futuro adicional:** se reentrenó con 2012–2024 y se evaluó con 2025–2026, que es como se usaría el modelo en la práctica.
- **Punto de comparación:** el baseline ingenuo "el próximo mes habrá los mismos hurtos que el mes pasado".

2. Comparación de los tres modelos supervisados

Modelo	MAE	MSE	RMSE	R^2	Mejora MAE vs. baseline	MAE prueba de futuro
Baseline (mes anterior)	0,915	12,76	3,57	0,967	—	1,069
Regresión Lineal	0,847	9,70	3,12	0,975	7,4 %	0,968
Random Forest	0,853	10,11	3,18	0,974	6,8 %	0,977
Gradient Boosting	0,874	11,71	3,42	0,970	4,5 %	0,985

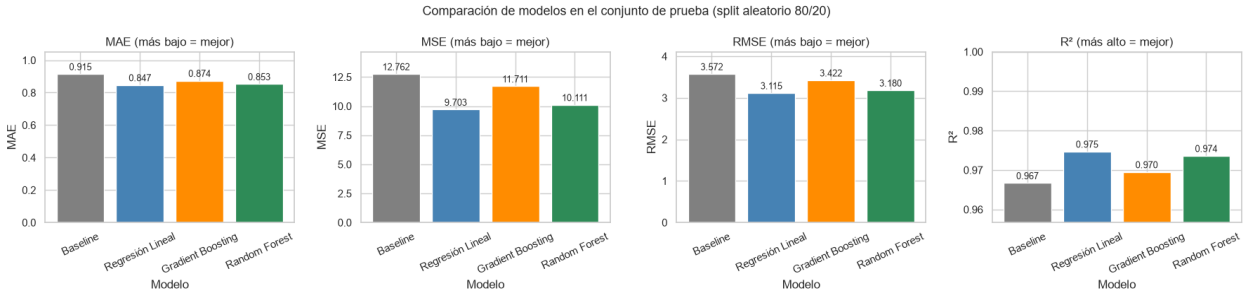


Figura 1. Métricas en el conjunto de prueba (split 80/20). MAE en motos por municipio-mes.

Lectura: los tres modelos superan al baseline y explican cerca del 97 % de la variación, con un error medio menor a 1 moto por municipio-mes. La mejora sobre el baseline es moderada porque el historial reciente ya contiene casi toda la señal: en Random Forest, las variables de rezago y promedio concentran el 99,7 % de la importancia, y el calendario y el departamento solo el 0,3 %. En la prueba de futuro todos los errores suben, pero el orden de los modelos se mantiene, y la ventaja sobre el baseline crece: la lineal baja el MSE de 23,3 a 15,7.

3. Segmentación no supervisada (K-Means)

Agrupamos los 1.042 municipios según su perfil en 2012–2024: volumen (log), % de meses sin hurto, variabilidad, tendencia y % de hurtos de autos. Probamos k = 2 a 8. k = 2 tiene el mejor Silhouette (0,403), pero solo separa municipios "con" y "sin" hurto. k = 5 mejora a k = 4 en ambos criterios y da grupos útiles: Silhouette = 0,335; Davies-Bouldin = 1,008.

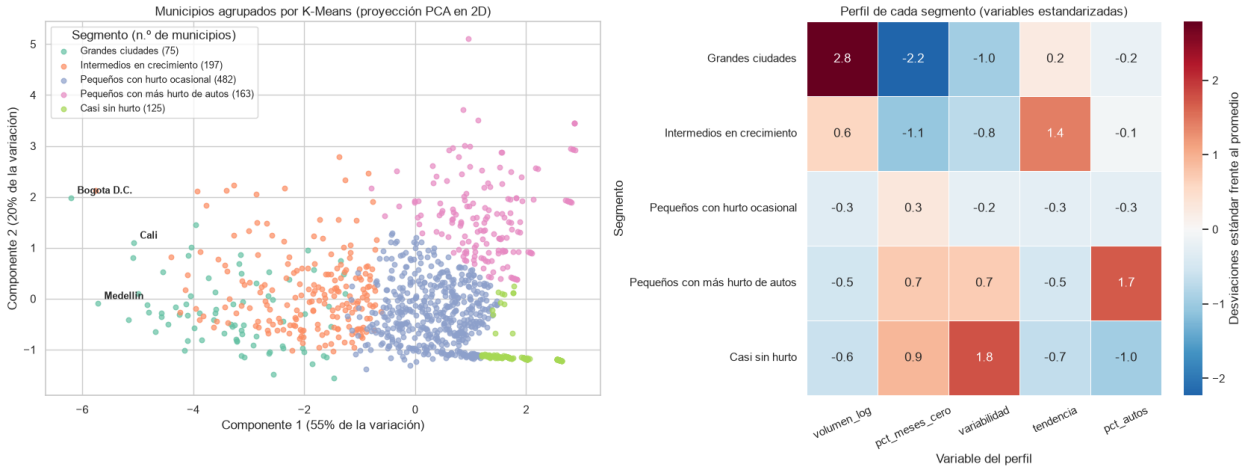


Figura 2. Izquierda: municipios en 2D (PCA). Derecha: perfil de cada segmento en desviaciones estándar frente al promedio.

Segmento	Municipios	Rasgo principal	Uso para el negocio
Grandes ciudades	75	≈ 28 motos/mes; 80 % de las motos hurtadas	Foco de control y operativos
Intermedios en crecimiento	197	≈ 1,9 motos/mes; el hurto casi se duplicó en 10 años (Soacha, Apartadó, Girón…)	Prevención temprana
Pequeños con hurto ocasional	482	≈ 0,3 motos/mes; 80 % de meses en cero	Vigilancia de rutina

Pequeños con más hurto de autos	163	44 % de los vehículos hurtados son automotores	Estrategia antirrobo de carros
Casi sin hurto	125	98 % de meses en cero	Sin acción específica

Cruce con los modelos: en grandes ciudades e intermedios los tres modelos mejoran claramente al baseline (la lineal baja el MAE de 6,13 a 5,38 y de 1,41 a 1,21). En los municipios casi sin hurto quedan peor (0,10 frente a 0,05), porque predicen valores pequeños positivos donde casi siempre hay 0. El valor del modelo está donde está el problema.

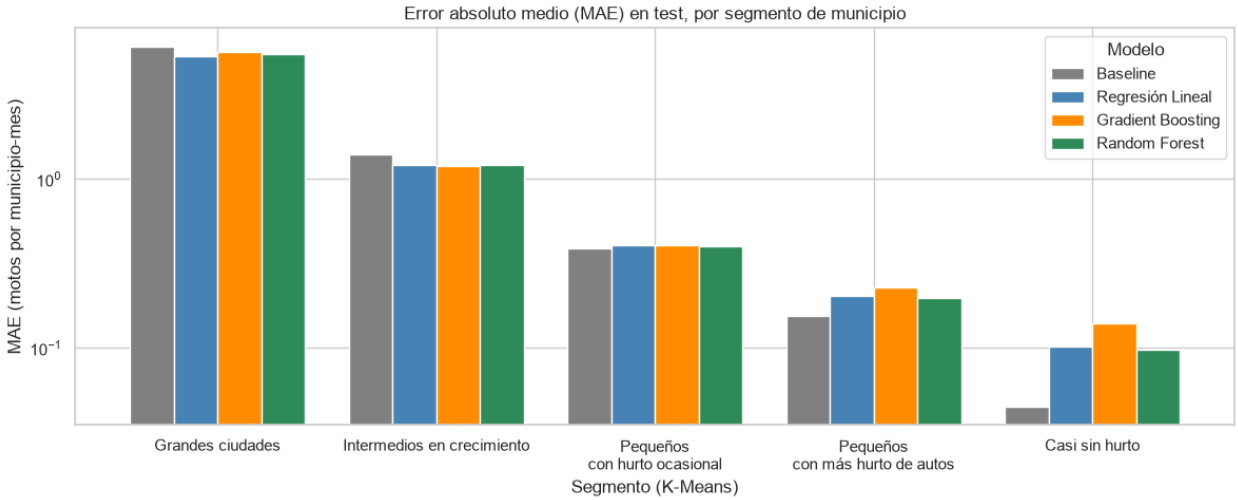


Figura 3. MAE en prueba por segmento y modelo (escala log).

4. Modelo elegido: Regresión Lineal

- **Por precisión:** es la mejor en las cuatro métricas (MAE 0,847; MSE 9,70; RMSE 3,12; R^2 0,975) y en la prueba de futuro (MAE 0,968), así que su ventaja no depende de cómo se partieron los datos.
- **Por interpretabilidad:** cada coeficiente se explica en palabras ("si el promedio de los últimos 3 meses sube, el pronóstico sube en proporción"). Un tomador de decisiones puede auditarla; Random Forest y Gradient Boosting son cajas negras en comparación.
- **Por simplicidad:** entrena en segundos, no tiene hiperparámetros que ajustar y es fácil de llevar a producción. Que el modelo más simple gane indica que la relación entre "cómo vienen los últimos meses" y "qué pasará el próximo" es casi lineal.

Matiz: puede predecir valores negativos (16 % de los casos de prueba), que se corrigen recortando en 0; las métricas reportadas ya incluyen ese ajuste. **Random Forest** queda como alternativa cercana (MAE 0,853) si se prefiere un modelo que nunca prediga negativos.