Proyecto 2 y 3 — Análisis, Limpieza y Modelado

Vale: 30% de la nota final (equivalente a Proyecto 2 20% + Proyecto 3 10%, unificados en un solo entregable).

Cubre: RA2 (limpieza y normalización) + RA3 (modelos supervisados y no supervisados).

Entrega: miércoles 28-oct o jueves 29-oct de 2026,

Grupos: los mismos del Proyecto 1.

Continuidad con el Proyecto 1

Este proyecto **continúa con el mismo dataset** que su grupo eligió del catálogo (proyectos/catalogo_datasets.md) y trabajó en el Proyecto 1. La idea es profundizar sobre el mismo caso de negocio: en el P1 lo exploraron y modelaron dimensionalmente, ahora lo limpian y le construyen modelos predictivos.

NO se permite cambiar de dataset entre proyectos salvo autorización explícita del profesor.

Objetivo

Aplicar los conocimientos adquiridos en **análisis exploratorio de datos, limpieza y normalización, y aprendizaje automático** (supervisado y no supervisado) sobre el dataset elegido en el Proyecto 1. Cada grupo debe llegar a modelos predictivos evaluados y comparados, listos para ser presentados.

Proyecto 2 – Introducción a la ciencia de los datos
Héctor Fabio Ocampo Arbeláez
R.A. 2 y 3

Fases y entregables

Fase A — Análisis Exploratorio del Dataset (20%)

Los estudiantes deben:

- Cargar el dataset en Python usando pandas.
- Generar visualizaciones exploratorias con matplotlib y seaborn (o plotly), aplicando lo aprendido en Clase 4 y Clase 5:
    - **Histogramas** de las variables numéricas.
    - **Boxplots** para detectar outliers.
    - **Heatmap de correlación** entre variables numéricas (Pearson y Spearman).
    - Al menos 2 gráficos adicionales del repertorio de la Clase 4/5 que aporten insight al dataset (barras, violin, scatter, pareto, líneas, etc.).
- Reportar hallazgos con lenguaje de negocio, no solo estadísticos.

Entregables:

- Notebook entrega/fase_a_eda.ipynb con código + gráficos + insights.
- Cada gráfico debe tener título, ejes rotulados y una celda Markdown "**Insight:**" debajo (2-3 frases).
- Documento breve (1-2 páginas) con los 3 hallazgos más importantes.

Fase B — Limpieza y Normalización de Datos (30%)

Los estudiantes deben:

- **Diagnosticar** nulos, duplicados, inconsistencias de texto y outliers.
- **Manejar los valores nulos** con al menos 2 estrategias distintas según el tipo de variable (media/mediana/moda/KNN). Justificar la elección para cada columna.
- **Detectar y tratar valores atípicos** con IQR o Z-score. Decidir explícitamente si se eliminan o se conservan y justificar.
- **Convertir variables categóricas** a numéricas:
    - One-Hot Encoding (pd.get_dummies con drop_first=True) para variables nominales.
    - Ordinal Encoding para variables con orden natural.
- **Estandarizar y normalizar** las variables numéricas (Min-Max, Z-score o RobustScaler según el caso).

- **Aplicar transformación logarítmica** (o Box-Cox / Yeo-Johnson) si alguna variable tiene distribución muy sesgada.
- Guardar el DataFrame limpio en entrega/datos_limpios.parquet.

Entregables:

- Notebook entrega/fase_b_limpieza.ipynb con el pipeline completo.
- Documento breve con los pasos seguidos y la justificación de cada decisión (por qué media vs mediana, por qué OneHot vs Ordinal, etc.).

Fase C — Implementación de Modelos Predictivos (30%)

Los estudiantes deben entrenar y evaluar **al menos 3 modelos** de Machine Learning aplicados a la variable objetivo del dataset. Además, aplicar **al menos 1 modelo no supervisado** (clustering) para segmentación.

Modelos posibles según el tipo de problema:

Tipo de problema	Modelos sugeridos
Regresión (target continuo)	Regresión Lineal, Random Forest Regressor, Redes Neuronales (MLPRegressor), Gradient Boosting
Clasificación (target discreto)	K-Nearest Neighbors, Árboles de Decisión, Support Vector Machines, Random Forest Classifier, Regresión Logística
Agrupamiento (no supervisado)	K-Means (con Silhouette Score), DBSCAN, clustering jerárquico

Comparación obligatoria de los 3 modelos supervisados mediante métricas apropiadas:

- Regresión: MSE, RMSE, R^2, MAE.
- Clasificación: Accuracy, Precision, Recall, F1-score, matriz de confusión.
- Clustering: Silhouette Score, Davies-Bouldin.

Requerido: aplicar train_test_split (80/20 o 70/30) y evaluar en el conjunto de prueba, NO en el de entrenamiento.

Prohibido explícitamente:

- Normalizar antes del split (**data leakage** — se cubre en Clase 12; anticiparlo aquí es buena práctica).
- Evaluar con las mismas filas usadas para entrenar.

Entregables:

- Notebook entrega/fase_c_modelos.ipynb con el código de los 4 modelos (3 supervisados + 1 no supervisado).
- Tabla comparativa de métricas.
- Documento con el análisis y la justificación del modelo elegido como final (¿por precisión? ¿por interpretabilidad? ¿por simplicidad?).

Fase D — Conclusiones y Presentación Final (20%)

En esta fase, los estudiantes deben:

- **Analizar los hallazgos** obtenidos en cada etapa del proyecto (Análisis, Limpieza, Modelado).
- **Explicar la efectividad** de los modelos predictivos y sugerir posibles mejoras (más datos, más features, hiperparámetros, otros algoritmos).
- **Elaborar visualizaciones finales** con los resultados de los modelos (comparación de métricas, matriz de confusión, curva ROC, dispersión predicho vs real, clusters visualizados).

Entregables:

- Informe final entrega/informe_p2p3.pdf de 6-8 páginas con:
  - Contexto del dataset y pregunta de negocio.
  - Resumen del análisis exploratorio (con 2-3 gráficos clave).
  - Técnicas de limpieza y normalización utilizadas.
  - Modelos entrenados y comparación de desempeño.
  - Conclusiones y posibles mejoras.
- Presentación oral de 8-10 minutos por grupo en la Clase 9 (28-29 oct).

Rúbrica detallada

Criterio	%	Descriptores

Proyecto 2 – Introducción a la ciencia de los datos
Héctor Fabio Ocampo Arbeláez
R.A. 2 y 3

Fase A — EDA	20 %	20 hallazgos claros + gráficos con insights · 15 gráficos correctos pero insights débiles · 8 pocos gráficos o mal etiquetados · 0 no entregado
Fase B — Limpieza	30 %	30 pipeline completo justificado + encoding + transformaciones · 22 pipeline con omisiones menores · 12 limpieza superficial · 0 no entregado
Fase C — Modelos	30 %	30 los 4 modelos + comparación + justificación del elegido · 22 los 4 modelos sin comparación clara · 12 menos de 4 modelos · 0 no entregado
Fase D — Conclusiones	20 %	20 informe claro + presentación fluida · 15 informe débil · 8 sin presentación · 0 no entregado

Fechas clave

- **28-oct (miércoles) / 29-oct (jueves):** entrega final y presentación oral.

Estructura del entregable

```
grupo-N-p2p3.zip
 ├── entrega/
 │    ├── fase_a_eda.ipynb
 │    ├── fase_b_limpieza.ipynb
 │    ├── fase_c_modelos.ipynb
 │    ├── datos_limpios.parquet
 │    ├── informe_p2p3.pdf
 │    └── presentacion.pdf
 ├── .env.example
 ├── requirements.txt
 └── README.md  ← cómo correr el proyecto
```